第十章: 代码案例学习: 解析二进制数据格式

本章将会讨论一个常见任务:解析(parsing)二进制文件。选这个任务有两个目的。第一个确实是想谈谈解析过程,但更重要的目标是谈谈程序组织、重构和消除样板代码(boilerplate code:通常指不重要,但没它又不行的代码)。 我们将会展示如何清理冗余代码,并为第十四章讨论 Monad 做点准备。

我们将要用到的文件格式来自于 netpbm 库,它包含一组用来处理位图图像的程序及文件格式,它古老而令人尊敬。 这种文件格式不但被广泛使用,而且还非常简单,虽然解析过程也不是完全没有挑战。 对我们而言最重要的是,netpbm 文件没有经过压缩。

灰度文件

netpbm 的灰度文件格式名为 PGM("portable grey map")。事实上它不是一个格式,而是两个: 纯文本(又名P2)格式使用 ASCII 编码,而更常用的原始(P5)格式则采用二进制表示。

每种文件格式都包含头信息,头信息以一个"魔法"字符串开始,指出文件格式。纯文本格式是 P2,原始格式是 P5。 魔法字符串之后是空格,然后是三个数字:宽度、高度、图像的最大灰度值。 这些数字用十进制 ASCII 数字表示,并用空格隔开。

最大灰度值之后便是图像数据了。在原始文件中,这是一串二进制值。纯文本文件中,这些值是用空格隔开的十进制 ASCII 数字。

原始文件可包含多个图像,一个接一个,每个都有自己的头信息。纯文本文件只包含一个图像。

解析原始 PGM 文件

首先我们来给原始 PGM 文件写解析函数。PGM 解析函数是一个纯函数。它不管获取数据,只管解析。 这是一种常见的 Haskell 编程方法。通过把数据的获取和处理分开,我们可以很方便地控制从哪里获取数据。

我们用 ByteString 类型来存储灰度数据,因为它比较节省空间。 由于 PGM 文件以 ASCII 字符串开头,文件内容又是二进制数据,我们同时载入两种形式的 ByteString 模块。

```
-- file: ch10/PNM.hs
import qualified Data.ByteString.Lazy.Char8 as L8
import qualified Data.ByteString.Lazy as L
import Data.Char (isSpace)
```

我们并不关心 ByteString 类型是惰性的还是严格的,因此我们随便选了惰性的版本。

我们用一个直白的数据类型来表示 PGM 图像。

```
-- file: ch10/PNM.hs

data Greymap = Greymap {
    greyWidth :: Int
    , greyHeight :: Int
    , greyMax :: Int
    , greyData :: L. ByteString
    } deriving (Eq)
```

通常来说,Haskell 的 Show 实例会生成数据的字符串表示,我们还可以用 read 读回来。 然而,对于一个位图图像文件来说,这可能会生成一个非常大的字符串,比如当你对一张照片调用 show 的时候。 基于这个原因,我们不准备让编译器自动为我们派生 Show 实例;我们会自己实现,并刻意简化它。

```
-- file: ch10/PNM.hs
instance Show Greymap where
show (Greymap w h m _) = "Greymap" ++ show w ++ "x" ++ show h + "" ++ show m
```

我们的 Show 实例故意没打印位图数据,也就没必要写 Read 实例了,因为我们无法从 Show 的结果重构 Greymap。

解析函数的类型显而易见。

```
— file: ch10/PVM.hs
parseP5 :: L.ByteString → Maybe (Greymap, L.ByteString)
```

这个函数以一个 ByteString 为参数,如果解析成功的话,它返回一个被解析的 Greymap 值以及解析之后剩下的字符串,剩下的字符串以后会用到。

解析函数必须一点一点处理输入数据。首先,我们必须确认我们正在处理的是原始 PGM 文件; 然后,我们处理头信息中的数字;最后我们处理位图数据。下面是是一种比较初级的实现方法,我们会在它的基础上不断改进。

```
-- file: ch10/PNM hs
matchHeader :: L. ByteString -> L. ByteString -> Maybe L. ByteString
-- "nat" here is short for "natural number"
getNat :: L.ByteString -> Maybe (Int, L.ByteString)
getBytes :: Int -> L.ByteString
        -> Maybe (L. ByteString, L. ByteString)
parseP5 s =
 case matchHeader (L8. pack "P5") s of
   Nothing → Nothing
   Just s1 →
     case getNat sl of
       Nothing -> Nothing
       Just (width, s2) ->
         case getNat (L8. dropWhile isSpace s2) of
           Nothing → Nothing
           Just (height, s3) ->
             case getNat (L8. dropWhile isSpace s3) of
               Nothing → Nothing
               Just (maxGrey, s4)
                 maxGrey > 255 -> Nothing
                 otherwise ->
                     case getBytes 1 s4 of
                       Nothing → Nothing
                       Just (_, s5) →
                         case getBytes (width * height) s5 of
                           Nothing → Nothing
                           Just (bitmap, s6) ->
                             Just (Greymap width height maxGrey bitmap, s6)
```

这段代码非常直白,它把所有的解析放在了一个长长的梯形 case 表达式中。每个函数在处理完它所需要的部分后会把剩余的 ByteString 返回。 我们再把这部分传给下个函数。像这样我们将结果依次解构,如果解析失败就返回 Nothing,否则便又向最终结迈近了一步。 下面是我们在解析过程中用到的函数的定义。它们的类型被注释掉了因为已经写过了。

```
-- file: ch10/PNM.hs
-- L. ByteString -> L. ByteString -> Maybe L. ByteString
matchHeader prefix str
    | prefix `L8.isPrefixOf` str
       = Just (L8. dropWhile isSpace (L. drop (L. length prefix) str))
    otherwise
        = Nothing
-- L. ByteString -> Maybe (Int, L. ByteString)
getNat s = case L8. readInt s of
            Nothing → Nothing
             Just (num, rest)
                             -> Nothing
                 num <= 0
                 otherwise -> Just (num, L8. dropWhile isSpace rest)
-- Int -> L. ByteString -> Maybe (L. ByteString, L. ByteString)
getBytes n str = 1et count
                            = fromIntegral n
                    both@(prefix,_) = L.splitAt count str
                 in if L. length prefix < count
                   then Nothing
                    else Just both
```

消除样板代码

Ø v: latest ▼

parseP5 函数虽然能用,但它的代码风格却并不令人满意。它不断挪向屏幕右侧,非常明显,再来个稍微复杂点的函数它就要横跨屏幕了。 我们不断构建和解构 Maybe 值,只在 Just 匹配特定值的时候才继续。所有这些相似的 case 表达式就是"样板代码",它掩盖了我们真正要做的事情。 总而言之,这段代码需要抽象重构。

退一步看,我们能观察到两种模式。第一,很多我们用到的函数都有相似的类型,它们最后一个参数都是 ByteString, 返回值类型都是 Maybe。第二, parseP5 函数不断解构 Maybe 值, 然后要么失败退出,要么把展开之后的值传给下个函数。

我们很容易就能写个函数来体现第二种模式。

```
-- file: ch10/PNM.hs
(>>?) :: Maybe a -> (a -> Maybe b) -> Maybe b
Nothing >>? _ = Nothing
Just v >>? f = f v
```

(>>?) 函数非常简单:它接受一个值作为左侧参数,一个函数 f 作为右侧参数。如果值不为 Nothing,它就把函数 f 应用在 Just 构造器中的值上。我们把这个函数定义为操作符这样它就能把别的函数串联在一起了。最后,我们没给 (>>?) 定义结合度,因此它默认为 infixl g (左结合,优先级最高的操作符)。换言之, a >>? b >>? c 会从左向右求值,就像 (a >>? b) >>? c) 一样。

有了这个串联函数,我们来重写一下解析函数。

```
-- file: ch10/PNM.hs
parseP5_take2 :: L.ByteString -> Maybe (Greymap, L.ByteString)
parseP5\_take2 s =
   matchHeader (L8.pack "P5") s
                                     >>?
   \slash skipSpace ((), s)
                                     >>?
   (getNat . snd)
                                     >>?
   skipSpace
   \(width, s) \rightarrow  getNat s
                                     >>?
   skipSpace
                                     >>?
   >>?
   \(maxGrev, s) -> getBvtes 1 s
                                     >>?
    (getBytes (width * height) . snd) >>?
   \(bitmap, s) -> Just (Greymap width height maxGrey bitmap, s)
skipSpace :: (a, L. ByteString) -> Maybe (a, L. ByteString)
skipSpace (a, s) = Just (a, L8.dropWhile isSpace s)
```

理解这个函数的关键在于理解其中的链。每个 (>>?) 的左侧都是一个 Maybe 值,右侧都是一个返回 Maybe 值的函数。 这样, Maybe 值就可以不断传给后续 (>>?) 表达式。

我们新增了 skipSpace 函数用来提高可读性。通过这些改进,我们已将代码长度减半。通过移除样板 case 代码,代码变得更容易理解。

尽管在**匿名 (lambda) 函数**中我们已经警告过不要过度使用匿名函数,在上面的函数链中我们还是用了一些。因为这些函数太小了,给它们命名并不能提高可读性。

隐式状态

到这里还没完。我们的代码显式地用序对传递结果,其中一个元素代表解析结果的中间值,另一个代表剩余的 ByteString 值。 如果我们想扩展代码,比方说记录已经处理过的字节数,以便在解析失败时报告出错位置,那我们已经有8个地方要改了,就为了把序对改成三元组。

这使得本来就没多少的代码还很难修改。问题在于用模式匹配从序对中取值:我们假设了我们总是会用序对,并且把这种假设编进了代码。尽管模式匹配非常好用,但如果不慎重,我们还是会误入歧途。

让我们解决新代码带来的不便。首先,我们来修改解析状态的类型。

我们转向了代数数据类型,现在我们既可以记录当前剩余的字符串,也可以记录相对于原字符串的偏移值了。 更重要的改变是用了记录语法:现在可以避免使用模式匹配来获取状态信息了,可以用 string 和 offset 访问函数。

我们给解析状态起了名字。给东西起名字方便我们推理。例如,我们现在可以这么看解析函数:它处理一个解析状态,产生新解析状态和一些别的信息。 我们可以用 Haskell 类型直接表示。

```
-- file: ch10/Parse.hs
simpleParse :: ParseState -> (a, ParseState)
simpleParse = undefined
```

为了给用户更多帮助,我们可以在解析失败时报告一条错误信息。只需对解析器的类型稍作修改即可。

```
-- file: ch10/Parse.hs
betterParse :: ParseState -> Either String (a, ParseState)
betterParse = undefined
```

为了防患于未然,我们最好不要将解析器的实现暴露给用户。早些时候我们显式地用序对来表示状态,当我们想扩展解析器的功能时, 我们马上就遇到了麻烦。为了防止这种现象再次发生,我们用一个newtype 声明来隐藏解析器的细节。

```
--file: ch10/Parse.hs

newtype Parse a = Parse {

runParse :: ParseState -> Either String (a, ParseState)
}
```

別忘了 newtype 只是函数在编译时的一层包装,它没有运行时开销。我们想用这个函数时,我们用 runParser 访问器。

如果我们的模块不导出 Parse 值构造器,我们就能确保没人会不小心创建一个解析器,或者通过模式匹配来观察其内部构造。

identity 解析器

我们来定义一个简单的 identity 解析器。它把输入值转为解析结果。从这个意义上讲,它有点像 id 函数。

```
-- file: ch10/Parse.hs
identity :: a -> Parse a
identity a = Parse (\s -> Right (a, s))
```

这个函数没动解析状态,只把它的参数当成了解析结果。我们把函数体包装成 Parse 类型以通过类型检查。 我们该怎么用它去解析呢?

首先我们得把 Parse 包装去掉从而得到里面的函数。这通过 runParse 函数实现。 然后得创建一个 ParseState, 然后对其调用解析函数。 最后, 我们把解析结果和最终的 ParseState 分开。

```
-- file: chl0/Parse.hs

parse :: Parse a -> L.ByteString -> Either String a

parse parser initState

= case runParse parser (ParseState initState 0) of

Left err -> Left err

Right (result, _) -> Right result
```

由于 identity 解析器和 parse 函数都没有检查解析状态,我们都不用传入字符串就可以试验我们的代码。

Ø v: latest ▼

一个不检查输入的解析器可能有点奇怪,但很快我们就可以看到它的用处。 同时,我们更加确信我们的类型是正确的,_{每个 J 胖 J} 代码是如何工作的。

记录语法、更新以及模式匹配

记录语法的用处不仅仅在于访问函数: 我们可以用它来复制或部分改变已有值。就像下面这样:

```
-- file: ch10/Parse.hs
modifyOffset :: ParseState -> Int64 -> ParseState
modifyOffset initState newOffset =
  initState { offset = newOffset }
```

这会创建一个跟 initState 完全一样的 ParseState 值,除了 offset 字段会替换成 newOffset 指定的值。

```
*Main> let before = ParseState (L8.pack "foo") 0
*Main> let after = modifyOffset before 3
*Main> before
ParseState {string = "foo", offset = 0}
*Main> after
ParseState {string = "foo", offset = 3}
```

在大括号里我们可以给任意多的字段赋值,用逗号分开即可。

一个更有趣的解析器

现在来写个解析器做一些有意义的事情。我们并不好高骛远: 我们只想解析单个字节而已。

定义中有几个新函数。

L8. uncons 函数取出 ByteString 中的第一个元素。

```
ghci> L8. uncons (L8. pack "foo")

Just ('f', Chunk "oo" Empty)

ghci> L8. uncons L8. empty

Nothing
```

getState 函数得到当前解析状态, putState 函数更新解析状态。bail 函数终止解析并报告错误。 (==>) 函数把解析器串联起来。我们马上就会详细介绍这些函数。

Note

Hanging lambdas

获取和修改解析状态

parseByte 函数并不接受解析状态作为参数。相反,它必须调用 getState 来得到解析状态的副本,然后调用 putState 将当前状态更新为新状态。

```
—— file: ch10/Parse.hs
getState :: Parse ParseState
```

```
getState = Parse (\s -> Right (s, s))
putState :: ParseState -> Parse ()
putState s = Parse (\_ -> Right ((), s))
```

阅读这些函数的时候,记得序对左元素为 Parse 结果,右元素为当前 ParseState。这样理解起来会比较容易。

getState 将当前解析状态展开,这样调用者就能访问里面的字符串。 putState 将当前解析状态替换为一个新状态。 (==>) 链中的下一个函数将会使用这个状态。

这些函数将显式的状态处理移到了需要它们的函数的函数体内。很多函数并不关心当前状态是什么,因而它们也不会调用 getState 或 putState。 跟之前需要手动传递元组的解析器相比,现在的代码更加紧凑。在之后的代码中就能看到效果。

我们将解析状态的细节打包放入 ParseState 类型中,然后我们通过访问器而不是模式匹配来访问它。 隐式地传递解析状态给我们带来另外的好处。如果想增加解析状态的信息,我们只需修改 ParseState 定义,以及需要新信息的函数体即可。 跟之前通过模式匹配暴露状态的解析器相比,现在的代码更加模块化:只有需要新信息的代码会受到影响。

报告解析错误

在定义 Parse 的时候我们已经考虑了出错的情况。(=>) 组合子不断检查解析错误并在错误发生时终止解析。 但我们还没来得及介绍用来报告解析错误的 bail 函数。

```
-- file: ch10/Parse.hs
bail :: String -> Parse a
bail err = Parse $ \s -> Left $
  "byte offset " ++ show (offset s) ++ ": " ++ err
```

调用 bail 之后,(==>) 会模式匹配包装了错误信息的 Left 构造器,并且不会调用下一个解析器。 这使得错误信息可以沿着调用链返回。

把解析器串联起来

(==>) 函数的功能和之前介绍的(>>?) 函数功能类似:它可以作为"胶水"把函数串联起来。

(==>) 函数体很有趣,还稍微有点复杂。回想一下,Parse 类型表示一个被包装的函数。 既然 (==>) 函数把两个 Parse 串联起来并产生第三个,它也必须返回一个被包装的函数。

这个函数做的并不多:它仅仅创建了一个闭包 (closure) 用来记忆 firstParser 和 secondParser 的值。

Note

闭包是一个函数和它所在的环境,也就是它可以访问的变量。闭包在 Haskell 中很常见。 例如,(+5) 就是一个闭包。实现的时候必须将 5 记录为 (+) 操作符的第二个参数,这样得到的函数才能把 5 加给它的参数。

在应用 parse 之前,这个闭包不会被展开应用。 应用的时候,它会求值 firstParser 并检查它的结果。如果解析失败,闭包也会失败。 否则,它会把解析结果及 newState 传给 secondParser。

这是非常具有想象力、非常微妙的想法:我们实际上用了一个隐藏的参数将 ParseState 在 Parse 链之间传递。 (我们在之后几章还会碰到这样的代码,所以现在不懂也没有关系。)

Ø v: latest ▼

Functor 简介

现在我们对 map 函数已经有了一个比较详细的了解,它把函数应用在列表的每一个元素上,并返回一个可能包含另一种类型元素的列表。

```
ghci> map (+1) [1,2,3]
[2,3,4]
ghci> map show [1,2,3]
["1","2","3"]
ghci> :type map show
map show :: (Show a) => [a] -> [String]
```

map 函数这种行为在别的实例中可能有用。例如,考虑一棵二叉树。

```
-- file: ch10/TreeMap.hs

data Tree a = Node (Tree a)

| Leaf a

deriving (Show)
```

如果想把一个字符串树转成一个包含这些字符串长度的树,我们可以写个函数来实现:

```
-- file: ch10/TreeMap.hs
treeLengths (Leaf s) = Leaf (length s)
treeLengths (Node 1 r) = Node (treeLengths 1) (treeLengths r)
```

我们试着寻找一些可能转成通用函数的模式,下面就是一个可能的模式。

```
-- file: ch10/TreeMap.hs

treeMap :: (a -> b) -> Tree a -> Tree b

treeMap f (Leaf a) = Leaf (f a)

treeMap f (Node l r) = Node (treeMap f l) (treeMap f r)
```

正如我们希望的那样, treeLengths 和 treeMap length 返回相同的结果。

```
ghci> let tree = Node (Leaf "foo") (Node (Leaf "x") (Leaf "quux"))
ghci> treeLengths tree
Node (Leaf 3) (Node (Leaf 1) (Leaf 4))
ghci> treeMap length tree
Node (Leaf 3) (Node (Leaf 1) (Leaf 4))
ghci> treeMap (odd . length) tree
Node (Leaf True) (Node (Leaf True) (Leaf False))
```

Haskell 提供了一个众所周知的类型类来进一步一般化 treeMap。这个类型类叫做 Functor,它只定义了一个函数 fmap。

```
-- file: ch10/TreeMap.hs
class Functor f where
fmap :: (a -> b) -> f a -> f b
```

我们可以把 fmap 当做某种提升函数,就像我们在 Avoiding boilerplate with lifting(fix link) 一节中介绍的那样。 它接受一个参数为普通值 a -> b 的函数并把它提升为一个参数为容器 f a -> f b 的函数。 其中 f 是容器的类型。

举个例子,如果我们用 Tree 替换类型变量 f, fmap 的类型就会跟 treeMap 的类型相同。 事实上我们可以用 treeMap 作为 fmap 对 Tree 的实现。

```
-- file: ch10/TreeMap.hs
instance Functor Tree where
fmap = treeMap
```

我们可以用 map 作为 fmap 对列表的实现。

```
-- file: ch10/TreeMap. hs
instance Functor [] where
fmap = map
```

现在我们可以把 fmap 用于不同类型的容器上了。

```
ghci> fmap length ["foo", "quux"]
[3,4]
ghci> fmap length (Node (Leaf "Livingstone") (Leaf "I presume"))
Node (Leaf 11) (Leaf 9)
```

Prelude 定义了一些常见类型的 Functor 实例,如列表和 Maybe。

```
-- file: ch10/TreeMap.hs
instance Functor Maybe where
fmap _ Nothing = Nothing
fmap f (Just x) = Just (f x)
```

Maybe 的这个实例很清楚地表明了 fmap 要做什么。对于类型的每一个构造器,它都必须给出对应的行为。 例如,如果值被包装在 Just 里,fmap 实现把函数应用在展开之后的值上,然后再用 Just 重新包装起来。

Functor 的定义限制了我们能用 fmap 做什么。例如,如果一个类型有且仅有一个类型参数,我们才能给它实现 Functor 实例。

举个例子,我们不能给 Bither a b 或者 (a, b) 写 fmap 实现,因为它们有两个类型参数。 我们也不能给 Bool 或者 Int 写,因为它们没有类型参数。

另外,我们不能给类型定义添加任何约束。这是什么意思呢?为了搞清楚,我们来看一个正常的 data 定义和它的 Functor 实例。

```
-- file: ch10/ValidFunctor.hs
data Foo a = Foo a

instance Functor Foo where
fmap f (Foo a) = Foo (f a)
```

当我们定义新类型时,我们可以在 data 关键字之后加一个类型约束。

```
-- file: ch10/ValidFunctor.hs

data Eq a => Bar a = Bar a

instance Functor Bar where

fmap f (Bar a) = Bar (f a)
```

这意味着只有当 a 是 Eq 类型类的成员时,它才能被放进 Foo。 然而,这个约束却让我们无法给 Bar 写 Functor 实例。

给类型定义加约束不好

给类型定义加约束从来就不是什么好主意。它的实质效果是强迫你给每一个用到这种类型值的函数加类型约束。 假设我们现在有一个 栈数据结构,我们想通过访问它来看看它的元素是否按顺序排列。下面是数据类型的一个简单实现。

```
-- file: ch10/TypeConstraint.hs

data (Ord a) => OrdStack a = Bottom

| Item a (OrdStack a)

deriving (Show)
```

如果我们想写一个函数来看看它是不是升序的(即每个元素都比它下面的元素大), 很显然, 我们需要 Ord 约束来进行两两比较。

```
-- file: ch10/TypeConstraint.hs

isIncreasing :: (Ord a) => OrdStack a →> Bool

isIncreasing (Item a rest@(Item b _))
```

```
| a < b = isIncreasing rest
| otherwise = False
| isIncreasing _ = True
```

然而,由于我们在类型声明上加了类型约束,它最后也影响到了某些不需要它的地方:我们需要给 push 加上 Ord 约束,但事实上它并不关心栈里元素的顺序。

```
-- file: ch10/TypeConstraint.hs

push :: (Ord a) => a -> OrdStack a -> OrdStack a

push a s = Item a s
```

如果你把 Ord 约束删掉, push 定义便无法通过类型检查。

正是由于这个原因, 我们之前给 Bar 写 Functor 实例没有成功: 它要求 fmap 的类型签名加上 Eq 约束。

我们现在已经尝试性地确定了 Haskell 里给类型签名加类型约束并不是一个好的特性,那有什么好的替代吗? 答案很简单:不要在类型定义上加类型约束,在需要它们的函数上加。

在这个例子中,我们可以删掉 OrdStack 和 push 上的 Ord。 is Increasing 还需要,否则便无法调用()。现在我们只在需要的地方加类型约束了。 这还有一个更深远的好处:类型签名更准确地表示了每个函数的真正需求。

大多数 Haskell 容器遵循这个模式。Data. Map 模块里的 Map 类型要求它的键是排序的,但类型本身却没有这个约束。 这个约束是通过 insert 这样的函数来表达的,因为这里需要它,在 size 上却没有,因为在这里顺序无关紧要。

fmap 的中缀使用

你经常会看到 fmap 作为操作符使用:

```
ghci> (1+) `fmap` [1,2,3] ++ [4,5,6] [2,3,4,4,5,6]
```

也许你感到奇怪,原始的 map 却几乎从不这样使用。

我们这样使用 fmap 一个可能的原因是可以省略第二个参数的括号。括号越少读代码也就越容易。

```
ghci> fmap (1+) ([1,2,3] ++ [4,5,6]) [2,3,4,5,6,7]
```

如果你真的想把 fmap 当做操作符用, Control. Applicative 模块包含了作为 fmap 别名的(<\$>) 操作符。

当我们返回之前写的代码时, 我们会发现这对解析很有用。

灵活实例

你可能想给 Either Int b 类型实现 Functor 实例,因为它只有一个类型参数。

```
-- file: ch10/EitherInt.hs
instance Functor (Either Int) where
fmap _ (Left n) = Left n
fmap f (Right r) = Right (f r)
```

然而,Haskell 98 类型系统不能保证检查这种实例的约束会终结。非终结的约束检查会导致编译器进入死循环,所以这种形式的实例是被禁止的。

```
Prelude> :1 EitherInt.hs
[1 of 1] Compiling Main (EitherInt.hs, interpreted)

EitherInt.hs:2:10:

Illegal instance declaration for 'Functor (Either Int)'

(All instance types must be of the form (T al ... an)

where al ... an are *distinct type variables*,
and each type variable appears at most once in the instance head.
```

```
Use FlexibleInstances if you want to disable this.)
In the instance declaration for 'Functor (Either Int)'
Failed, modules loaded: none.
```

GHC 的类型系统比 Haskell 98 标准更强大。出于可移植性的考虑,默认情况下,它是运行在兼容 Haskell 98 的模式下的。 我们可以通过一个编译命令允许更灵活的实例。

```
-- file: ch10/EitherIntFlexible.hs
{-# LANGUAGE FlexibleInstances #-}

instance Functor (Either Int) where

fmap _ (Left n) = Left n

fmap f (Right r) = Right (f r)
```

这个命令内嵌于 LANGUAGE 编译选项。

有了 Functor 实例, 我们来试试 Either Int 的 fmap 函数。

更多关于 Functor 的思考

对于 Functor 如何工作,我们做了一些隐式的假设。 把它们说清楚并当成规则去遵守非常有用,因为这会让我们把 Functor 当成统一的、行为规范的对象。 规则只有两个,并且非常简单。

第一条规则是 Functor 必须保持身份 (preserve identity) 。也就是说,应用 fmap id 应该返回相同的值。

```
ghci> fmap id (Node (Leaf "a") (Leaf "b"))
Node (Leaf "a") (Leaf "b")
```

第二条规则是 Functor 必须是可组合的。 也就是说,把两个 fmap 组合使用效果应该和把函数组合起来再用 fmap 相同。

```
ghci> (fmap even . fmap length) (Just "twelve")

Just True
ghci> fmap (even . length) (Just "twelve")

Just True
```

另一种看待这两条规则的方式是 Functor 必须保持*结构*(shape)。集合的结构不应该受到 Functor 的影响,只有对应的值会改变。

```
ghci> fmap odd (Just 1)
Just True
ghci> fmap odd Nothing
Nothing
```

如果你要写 Functor 实例,最好把这些规则记在脑子里,并且最好测试一下,因为编译器不会检查我们提到的规则。 另一方面,如果你只是用 Functor,这些规则又如此自然,根本没必要记住。 它们只是把一些"照我说的做"的直觉概念形式化了。下面是期望行为的伪代码表示。

```
-- file: ch10/FunctorLaws.hs
fmap id == id
fmap (f . g) == fmap f . fmap g
```

给 Parse 写一个 Functor 实例

Ø v: latest ▼

对于到目前为止我们研究过的类型而言,fmap 的期望行为非常明显。然而由于 Parse 的复杂度,对于它而言 fmap 的期望行为并没有这么明显。 一个合理的猜测是我们要 fmap 的函数应该应用到当前解析的结果上,并保持解析状态不变。

```
-- file: ch10/Parse.hs
instance Functor Parse where
fmap f parser = parser ==> \result ->
identity (f result)
```

定义很容易理解,我们来快速做几个实验看看我们是否遵守了 Functor 规则。

首先我们检查身份是否被保持。我们在一次应该失败的解析上试试:从空字符串中解析字节(别忘了(<\$>)就是 fmap)。

```
ghci> parse parseByte L.empty
Left "byte offset 0: no more input"
ghci> parse (id <$> parseByte) L.empty
Left "byte offset 0: no more input"
```

不错。再来试试应该成功的解析。

```
ghci> let input = L8.pack "foo"
ghci> L.head input
102
ghci> parse parseByte input
Right 102
ghci> parse (id <$> parseByte) input
Right 102
```

通过观察上面的结果,可以看到我们的 Functor 实例同样遵守了第二条规则,也就是保持结构。 失败被保持为失败,成功被保持为成功。

最后, 我们确保可组合性被保持了。

```
ghci> parse ((chr . fromIntegral) <$> parseByte) input
Right 'f'
ghci> parse (chr <$> fromIntegral <$> parseByte) input
Right 'f'
```

通过这个简单的观察, 我们的 Functor 实例看起来行为规范。

利用 Functor 解析

我们讨论 Functor 是有目的的: 它让我们写出简洁、表达能力强的代码。回想早先引入的 parseByte 函数。 在重构 PGM 解析器使之使用新的解析架构的过程中,我们经常想用 ASCII 字符而不是 Word8 值。

尽管可以写一个类似于 parseByte 的 parseChar 函数,我们现在可以利用 Parse 的 Functor 属性来避免重复代码。 我们的 functor 接受一个解析结果并将一个函数应用于它,因此我们需要的是一个把 Word8 转成 Char 的函数。

```
-- file: ch10/Parse.hs
w2c :: Word8 -> Char
w2c = chr . fromIntegral
-- import Control.Applicative
parseChar :: Parse Char
parseChar = w2c <$> parseByte
```

我们也可以利用 Functor 来写一个短小的"窥视"函数。如果我们在输入字符串的末尾,它会返回 Nothing。 否则,它返回下一个字符,但不作处理(也就是说,它观察但不打扰当前的解析状态)。

```
-- file: ch10/Parse.hs

peekByte :: Parse (Maybe Word8)

peekByte = (fmap fst . L. uncons . string) ⟨$> getState
```

定义 parseChar 时用到的提升把戏同样也可以用于定义 peekChar。

```
-- file: ch10/Parse.hs

peekChar :: Parse (Maybe Char)

peekChar = fmap w2c <$> peekByte
```

注意到 peekByte 和 peekChar 分别两次调用了 fmap , 其中一次还是(〈\$〉)。 这么做的原因是 Parse (Maybe a) 类型是嵌在 Functor 中的 Functor。 我们必须提升函数两次使它能进入内部 Functor。

最后,我们会写一个通用组合子,它是 Parse 中的 takeWhile:它在谓词为 True 是处理输入。

```
-- file: ch10/Parse.hs

parseWhile :: (Word8 -> Bool) -> Parse [Word8]

parseWhile p = (fmap p <$> peekByte) ==> \mp ->

        if mp == Just True

        then parseByte ==> \b ->

            (b:) <$> parseWhile p

        else identity []
```

再次说明,我们在好几个地方都用到了 Functor(doubled up, when necessary)用以化简函数。 下面是相同函数不用 Functor 的版本。

```
-- file: ch10/Parse.hs

parseWhileVerbose p =

peekByte ==> \mc ->

case mc of

Nothing -> identity []

Just c | p c ->

parseByte ==> \b ->

parseWhileVerbose p ==> \bs ->

identity (b:bs)

otherwise ->

identity []
```

当你对 Functor 不熟悉的时候,冗余的定义应该会更好读。 但是,由于 Haskell 中 Functor 非常常见,你很快就会更习惯(包括读和写)简洁的表达。

重构 PGM 解析器

有了新的解析代码,原始 PGM 解析函数现在变成了这个样子:

```
-- file: ch10/Parse.hs

parseRawPGM =

parseWhileWith w2c notWhite ==> \header -> skipSpaces ==>&

assert (header == "P5") "invalid raw header" ==>&

parseNat ==> \width -> skipSpaces ==>&

parseNat ==> \height -> skipSpaces ==>&

parseNat ==> \maxGrey ->

parseByte ==>&

parseBytes (width * height) ==> \bitmap ->

identity (Greymap width height maxGrey bitmap)

where notWhite = (`notElem` " \r\n\t")
```

下面是定义中用到的辅助函数,其中一些模式现在应该已经非常熟悉了:

```
-- file: ch10/Parse.hs

parseWhileWith :: (Word8 → a) → (a → Bool) → Parse [a]

parseWhileWith f p = fmap f <$> parseWhile (p . f)

parseNat :: Parse Int

parseNat = parseWhileWith w2c isDigit ==> \digits →

if null digits

then bail "no more input"

else let n = read digits

in if n < 0
```

```
then bail "integer overflow"
else identity n

(=>&) :: Parse a -> Parse b -> Parse b

p =>& f = p ==> \_ -> f

skipSpaces :: Parse ()
skipSpaces = parseWhileWith w2c isSpace ==>& identity ()

assert :: Bool -> String -> Parse ()
assert True _ = identity ()
assert False err = bail err
```

类似于 (==>), (==>&) 组合子将解析器串联起来。但右侧忽略左侧的结果。 assert 使得我们可以检查性质,然后当性质为 False 时终止解析并报告错误信息。

未来方向

本章的主题是抽象。我们发现在函数链中传递显式状态并不理想,因此我们把这个细节抽象出来。 在写解析器的时候发现要重复用到一些代码,我们把它们抽象成函数。 我们引入了 Functor,它提供了一种映射到参数化类型的通用方法。

关于解析,我们在第16章会讨论一个使用广泛并且灵活的解析库 Parsec。 在第14章中,我们会再次讨论抽象,我们会发现用 Monad 可以进一步化简这章的代码。

Hackage 数据库中存在不少包可以用来高效解析以 ByteString 表示的二进制数据。在写作时,最流行的是 binary,它易用且高效。

练习

- 1. 给"纯文本" PGM 文件写解析器。
- 2. 在对"原始" PGM 文件的描述中,我们省略了一个细节。如果头信息中的"最大灰度"值小于256,那每个像素都会用单个字节表示。 然而,它的最大范围可达65535,这种情况下每个像素会以大端序的形式(最高有效位字节在前)用两个字节来表示。

重写原始 PGM 解析器使它能够处理单字节和双字节形式。

3. 重写解析器使得它能够区分"原始"和"纯文本" PGM 文件, 并解析对应的文件类型。

讨论

0条评论 Real World Haskll 中文版

● 登录

♡ 推荐

對 推文 f 分享

最新发布



开始讨论...

通过以下方式登录

或注册一个 DISQUS 帐号 ?

姓名

来做第一个留言的人吧!

在 REAL WORLD HASKLL 中文版 上还有

第十章: 代码案例学习: 解析二进制数据格式 — Real World Haskell 中文版

1条评论•4年前

Y — 此处少个"+": instance Show Greymap where show (Greymap w h m _) = "Greymap " ++ show w ++ "x" ++ show h ++ " " " ++ show m

Real World Haskell 中文版 — Real World Haskell 中文版

4条评论•6年前

Jojo — 更新好慢呀

第九章: I/O学习 —— 构建一个用于搜索文件系统的库 — Real World Haskell 中文版

3条评论•4年前

在原佐为 — "继续从左往右看" 这里英文是"from right to left",是从右到左吧。

第八章:高效文件处理、正则表达式、文件名匹配 — Real World Haskell 中文版

1条评论•4年前

Yutong Zhang —